Operating systems

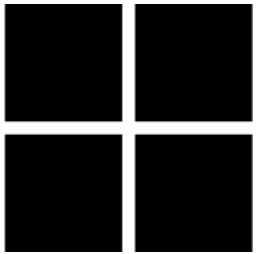

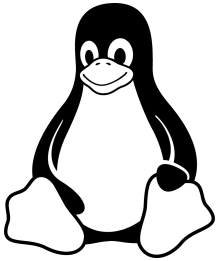

macOS

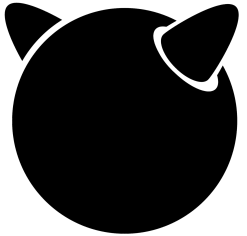

Многопоточность

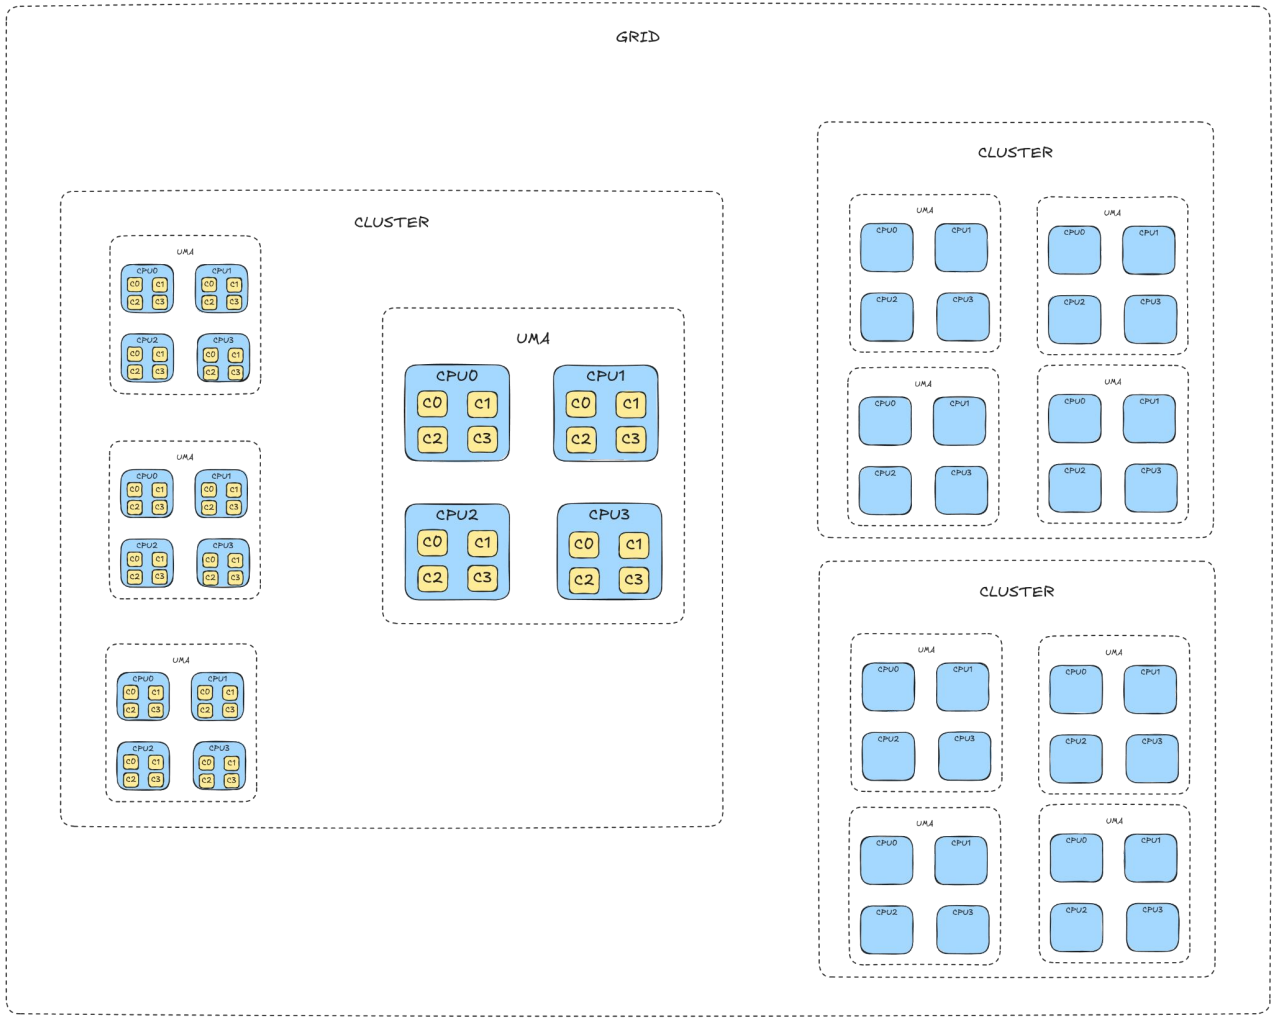
GRID
CLUSTER
UMA
CPU0
CPU1
CPU2
CPU3
C0
C1
C2
C3
CLUSTER
CLUSTER

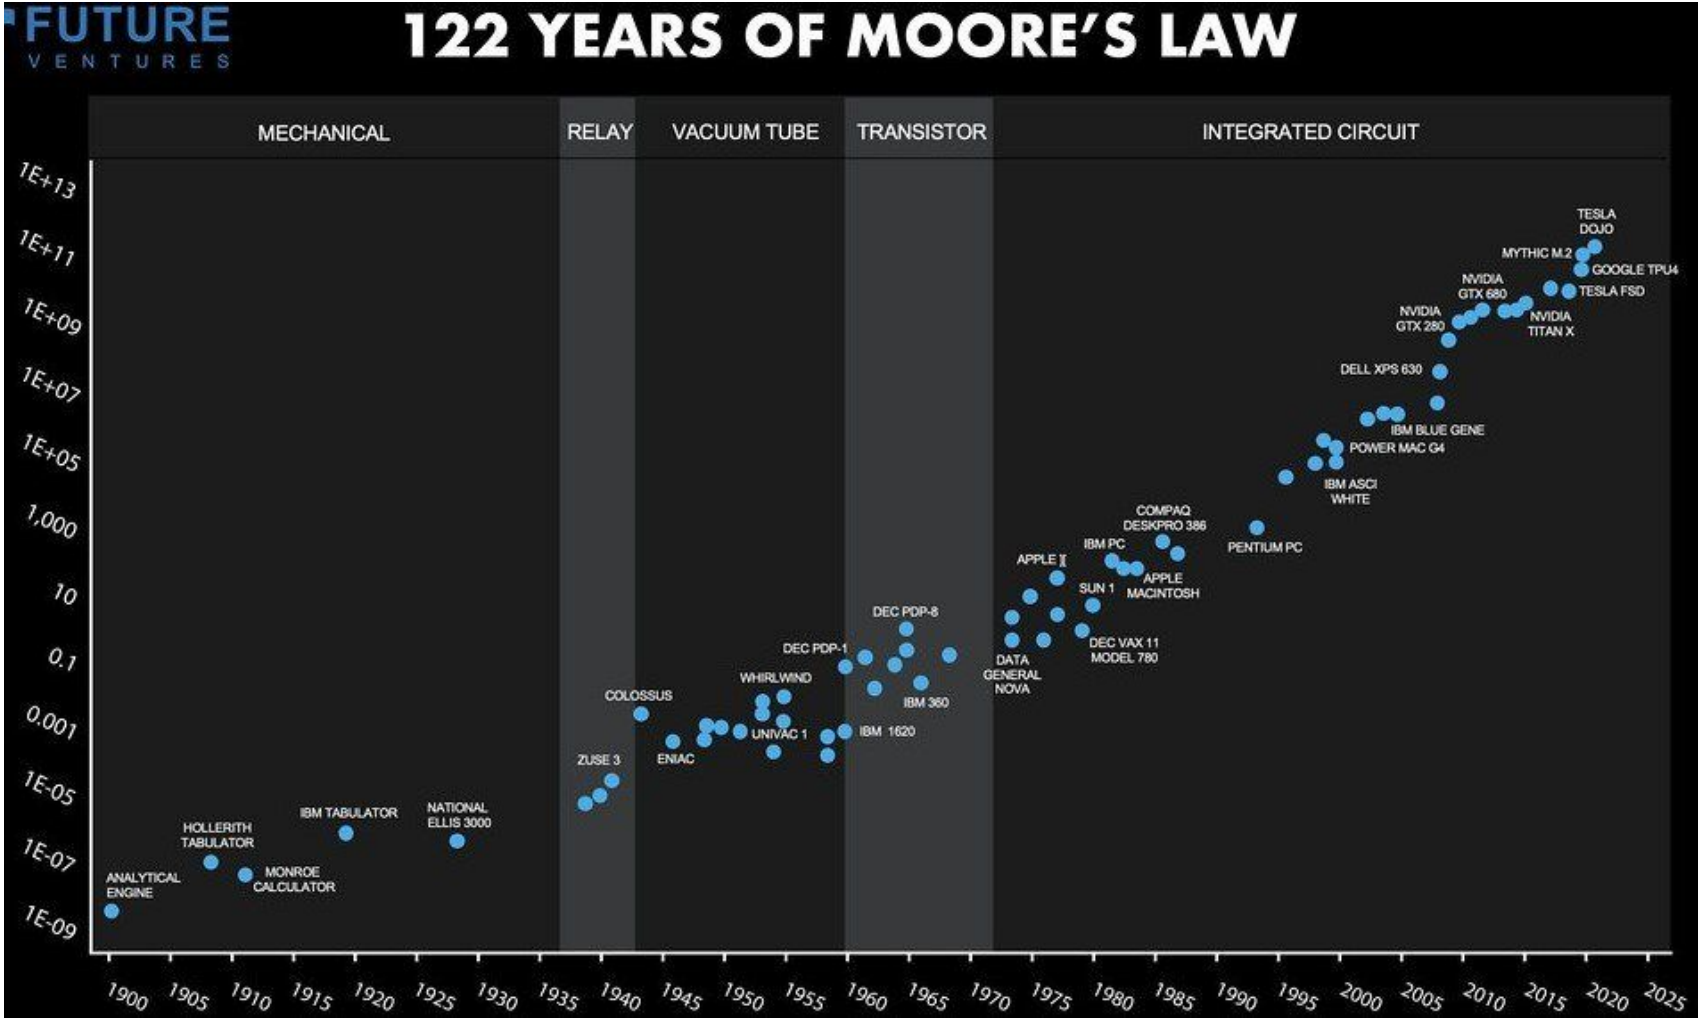
FUTURE VENTURES
122 YEARS OF MOORE'S LAW
MECHANICAL
RELAY
VACUUM TUBE
TRANSISTOR
INTEGRATED CIRCUIT
1E+13
1E+11
1E+09
1E+07
1E+05
1,000
10
0.1
0.001
1E-05
1E-07
1E-09
ANALYTICAL ENGINE
HOLLERITH TABULATOR
MONROE CALCULATOR
IBM TABULATOR
NATIONAL ELLIS 3000
ZUSE 3
COLOSSUS
ENIAC
WHIRLWIND
UNIVAC 1
IBM 1620
DEC PDP-1
DEC PDP-8
IBM 360
DATA GENERAL NOVA
APPLE II
SUN 1
DEC VAX 11 MODEL 780
IBM PC
COMPAQ DESKPRO 386
APPLE MACINTOSH
PENTIUM PC
IBM ASCI WHITE
POWER MAC G4
IBM BLUE GENE
DELL XPS 630
NVIDIA GTX 280
NVIDIA GTX 680
NVIDIA TITAN X
TESLA FSD
GOOGLE TPU4
MYTHIC M.2
TESLA DOJO
1900
1905
1910
1915
1920
1925
1930
1935
1940
1945
1950
1955
1960
1965
1970
1975
1980
1985
1990
1995
2000
2005
2010
2015
2020
2025

Классификация Флинна

- **SISD** (Single Instruction, Single Data) – одноядерные системы; параллельности нет
- **SIMD** (Single Instruction, Multiple Data) – векторные и графические процессоры; параллельная обработка данных (обработка изображений)
- **MISD** (Multiple Instruction, Single Data) – отказоустойчивые системы; несколько потоков команд выполняются над одним потоком данных; редко встречается, экзотика
- **MIMD** (Multiple Instruction, Multiple Data) – многоядерные процессоры, кластеры, суперкомпьютеры; полный, честный параллелизм; наиболее универсальные и распространенные архитектуры

SIMD

Процессоры предоставляют возможность обрабатывать группы данных (векторы) за “один” такт процессора:

- Векторные расширения x86_64: **MMX**, **SSE1/2/3/4**, **AVX1/2**, **AVX-512**
- Векторные расширения ARM: **Neon**

Используете специальные инструкции процессора, код становится не кроссплатформенным, компилятор редко видит возможность их использования, поэтому программисты пишут SIMD код самостоятельно

Пример с применением функции MADD (multiply-add) для большого потока данных

MIMD

Процессоры предоставляют возможность параллельного выполнения программ с помощью средств операционной системы:

- Процессов
  - преимущество в простоте написания кода
  - могут исполняться на множестве машин
  - операционная система использует защищенную модель памяти, что предотвращает доступ к памяти других процессов
  - более устойчивы к ошибкам, более надежнны
- Потоков: преимущество в **быстродействии!!!**

Говоря про быстродействие…

Мы будем пользоваться следующими метриками:

- **Ускорение:** $S = T_s / T_p$, где
  - T_s – время последовательной реализации,
  - T_p – время параллельной реализации,
  - $1 <= S <= p$,
  - p – количество ядер

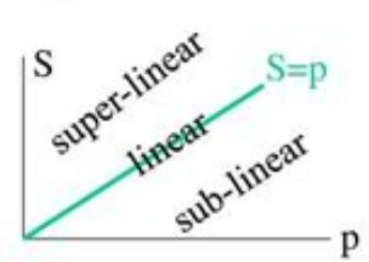

- **Эффективность**: $X = S / p$, где $X < 1$

Важный закон в параллельном программировании

Закон Амдала:

$$S_p = \frac{1}{\alpha + \frac{1-\alpha}{p}}$$

- a – доля последовательного кода (0 < a <= 1)
- p – количество ядер

Показывает верхнюю оценку ускорения: чем больше последовательных участков в коде будет организовано, тем меньше потенциальное ускорение.

Потоки

Threads (нити, треды, легковесные процессы) — потоки исполнения в общем адресном пространстве. Способ выполнения множества программ в одном процессе.

Они полезны, потому что:

- можно одновременно преобразовывать единые данные разными способами (функциями)
- создание потоков быстрее, чем создание процесса
- наиболее эффективны в мультипроцессорных системах

Свойства потоков

- У каждого процесса при старте есть единственный поток управления (*main*)
- Потоки могут создавать новые в пределах одного процесса
- Все потоки в пределах одного процесса имеют общие сегменты данных и кода (находятся в одном адресном пространстве процесса)
- Каждый поток имеет свой стек

Единицей планирования в ядре ОС является именно **поток**!

Отличия потоков от процессов

Процесс	Поток
● Данные для управления памятью процесса ● Учетная информация (им, пользователь, время, ID и пр.) ● Информация об используемых процессом объектов OS ● Исполняемый код и данные в адресном пространстве ● Таблица потоков	● Состояние процесса ● Указатель инструкции / программный счетчик ● Содержание регистров ● Данные для планирования использования CPU ● Стек

Стратегии реализации потоков

- Потоки уровня ядра (KLT):
  - Потоки полностью управляются ядром ОС и имею свою запись в таблице потоков ядра
  - *Высокая степень* параллелизма и *устойчивость* :)
  - Высокие накладные расходы на переключение контекста, так как ядро участвует в каждом переключении :(

- Потоки уровня пользователя (ULT):
  - Потоки управляются библиотекой в пользовательском пространстве, ядро не знает о них, и переключение потоков происходит без обращения к ядру
  - Высокая производительность и гибкость в реализации :)
  - Блокировка одного потока может заблокировать весь процесс :(

Эффективная реализация лежит где-то по-середине…

Стратегии реализации потоков

Гибридная модель

- Пользовательские потоки мультиплексируются на меньшее количество ядерных потоков
- Соблюдается баланс между производительностью и параллелизмом, но сложны в реализации

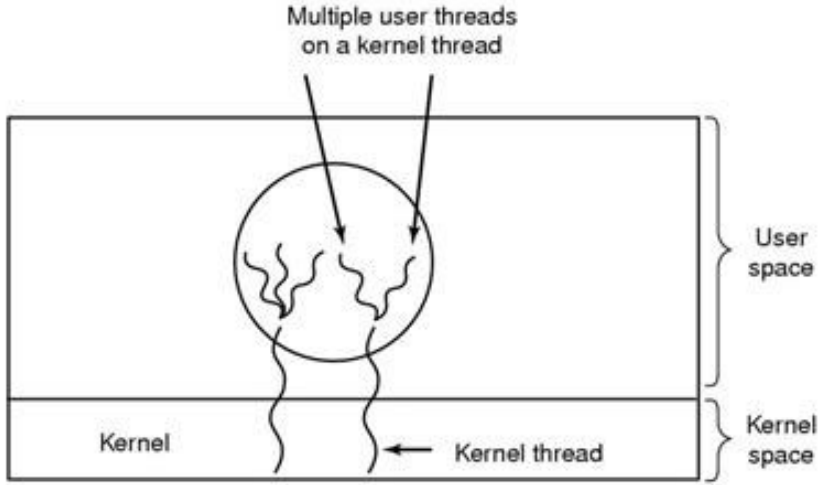

Fork & Join модель

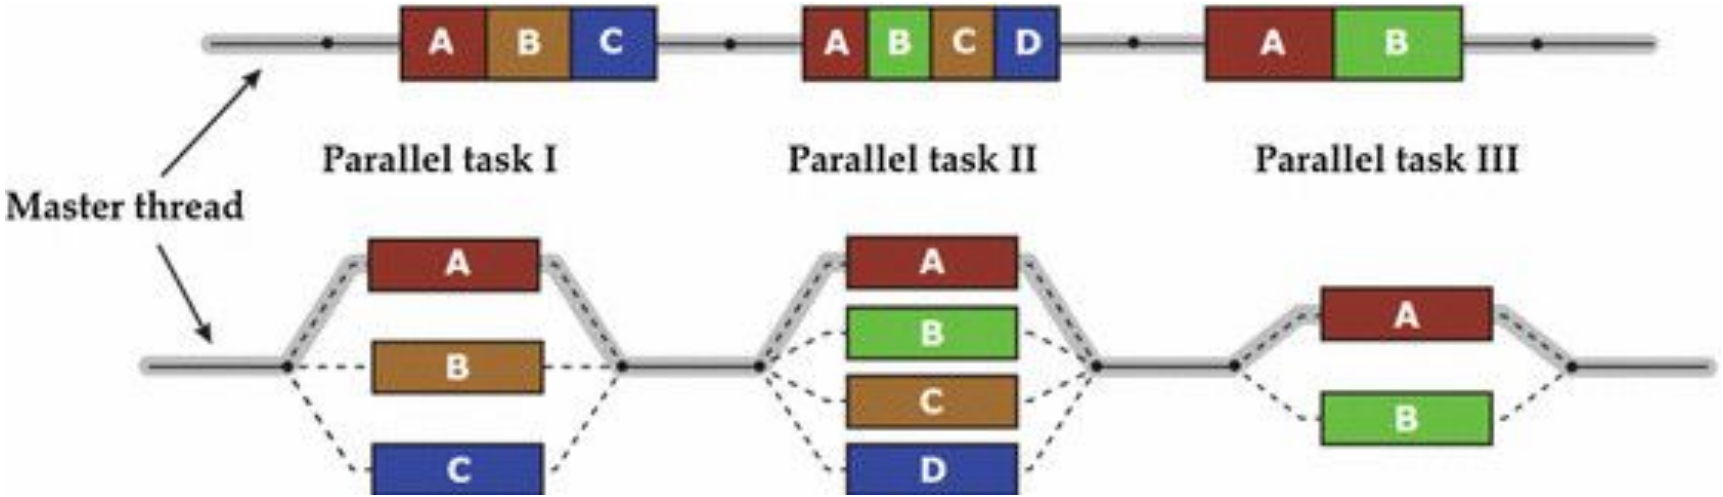

Псевдопараллелизм

В Fork & Join модели **нет ограничения по количеству** создаваемых потоков.

Если создать потоков больше, чем логических процессоров в системе, то вы будете наблюдать **псевдопараллелизм** – ситуация, когда задачи будут исполнены на ядрах количестве больше одного.

Поскольку ядру ОС придётся планировать больше потоков, соответственно ядро будет испытывать **накладные расходы** (**overhead**) на переключение контекста исполнения и истинное ускорение вы не увидите.

А увидите даже замедление, если overhead больше чем выполненная работа

Ещё больше накладок

В Fork & Join модели подразумевается, что выполнение параллельных заданий должно сопровождаться **созданием, ожиданием и уничтожением** потоков. **И так каждый раз, когда нужно выполнить задание!**

Создание, ожидание и удаление – дополнительные накладки по эффективности вашей программы. С ними нужно бороться!

То есть Fork & Join модель **не позволяет** выделить группу потоков и менять им задание как только они отработали. Есть более эффективный механизм, но Fork & Join прост в реализации, поэтому будем пользоваться им

Примитивы синхронизации

Это механизмы в программировании, предоставляемые средствами ядра ОС и библиотекой, которые используются для управления доступом к ***общим ресурсам***, в которые одновременно ***пишут и читают***, в параллельных системах, чтобы избежать ***гонки данных*** и обеспечить ***монопольный*** доступ ***одному*** потоку.

Общими ресурсами могут быть память, файлы, базы данных и т.п. куда производятся и запись, и чтение одновременно.

Гонка данных – это ошибка :(

Два или более потока одновременно могут обратиться к одной и той же области памяти, и хотя бы один из них выполнит запись. Это приведет к непредсказуемым результатам, так как порядок операций не определён.

Порядок операций не определён, потому что потоки выполняются параллельно и независимо друг от друга. Кто-то выполняется быстрее, кто-то медленнее и эта скорость выполнения постоянно меняется

Программирование между строк

Посмотрим на простейший пример гонки данных – инкремент числа:

```
increment(volatile int *x):
        mov     eax, DWORD PTR [rdi] ; Загружаем 'x' из памяти в регистр
        inc     eax                  ; Инкрементируем
        mov     DWORD PTR [rdi], eax ; Загружаем новый 'x' обратно в память
```

Первый поток		Второй поток
mov: eax = x = 0	**Мы хотим получить x = 2, но…**	mov: eax = x = 0
inc: eax = 1		inc: eax = 1
mov: x = eax = 1		mov: x = eax = 1

Такое **может** произойти, а может и нет. Если ***когда-то может***, то это нужно исправлять!

Mutex, как простое решение проблемы!

Мьютекс – простейший примитив синхронизации, используемый для предоставления монопольного доступа к общему ресурсу.

- Имеет два состояния: разблокированный и заблокированный, т.е. похож на **bool**
- Имеет простой интерфейс: **lock** и **unlock**
- Оборачивайте куски кода в lock и unlock и проблема “решена”

Если поток пытается блокировать разблокированный mutex, то поток блокирует mutex и имеет монопольный доступ к ресурсу, который он охраняет

Если поток пытается заблокировать заблокированный mutex, то поток будет спать, пока mutex вдруг не станет разблокированным

Mutex – простое “решение” проблемы

На самом деле, каждый раз, когда мы оборачиваем куски кода в lock и unlock, мы организовываем больше последовательных участков.

Это значит, что злоупотребление примитивами синхронизации снижает потенциальное ускорение по закону Амдала!

Такие гарантированно последовательные участки кода, где организован монопольный доступ к ресурсам (захват, пользование, освобождение), называются ***критическими секциями***.

Критические секции

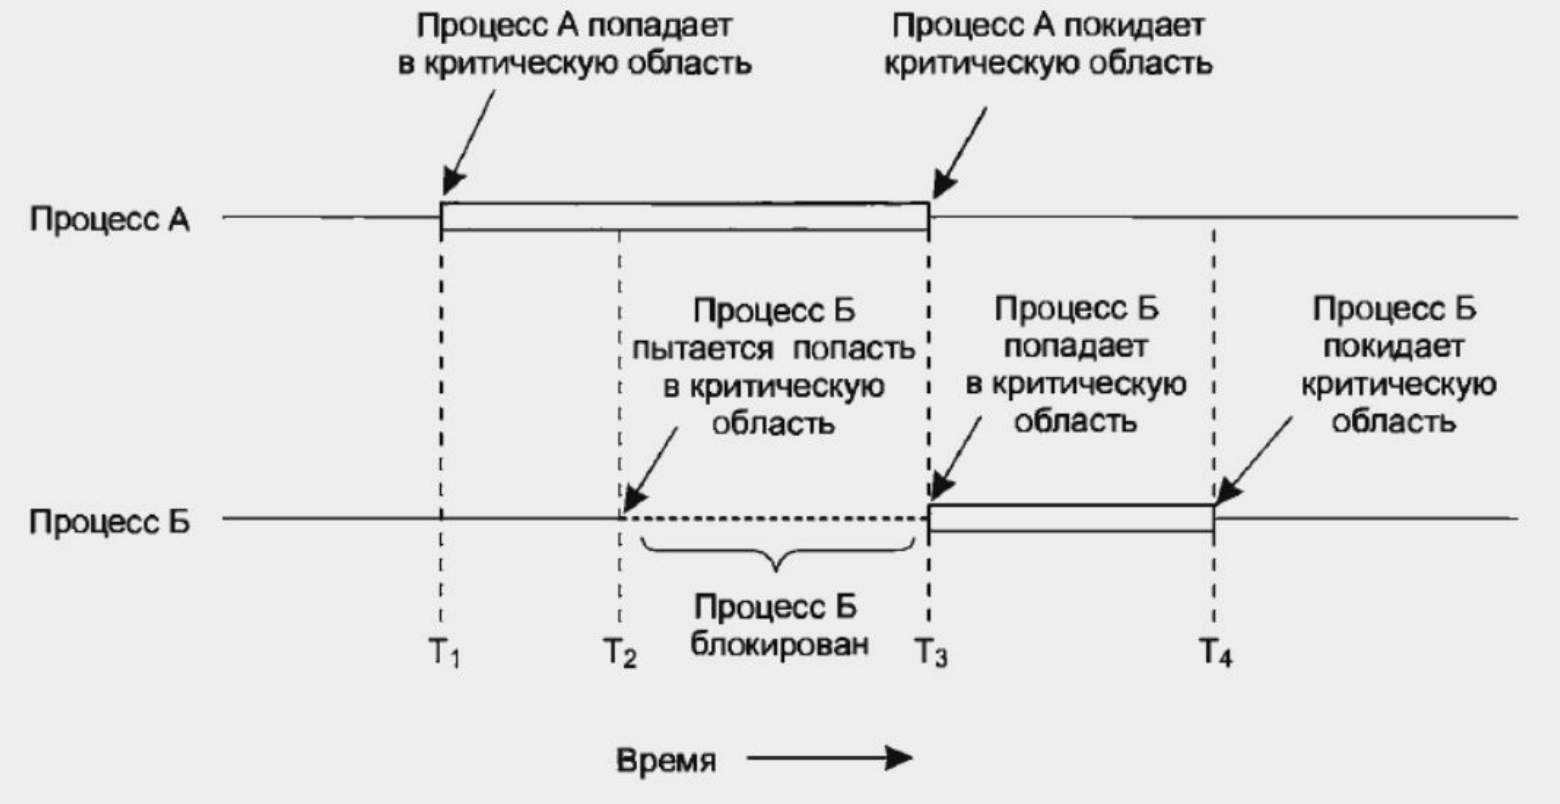

Пытайтесь делать таких участков меньше!

Пытайтесь делать так, чтобы каждый поток работал только со своей копией данных! Таким образом, отпадает нужда в синхронизации.

Если потоки модифицируют свои области общих входных данных, то старайтесь записывать результат в свои, для каждого потока, массивы, которые вы потом объедините!

Но если архитектура кода и задача так сделать не позволяет, то используйте примитивы синхронизации.

Я рекомендую подумать над организацией памяти для потоков при решении задачи с помощью параллельного программирования, прежде чем везде лепить мьютексы!

Попробуем написать mutex сами!

```
struct Mutex {
    bool flag[2];
};

void lock(Mutex *mutex) {
    int i = gettid(); // Для этого примера считаем, что
    int j = 1 - i;    // потоков всего может быть 2 на процесс
    mutex->flag[i] = true;
    while (flag[j]);  // Просто ждём, ничего не делаем
}

void unlock(Mutex *mutex) {
    int i = gettid();
    flag[i] = false;
}
```

Тут, кажется, есть проблема…

Взаимоблокировка (deadlock)

Такая ситуация в многопоточных программах, когда два или более потока бесконечно ждут друг друга, чтобы освободить ресурсы, которые они удерживают, и не могут продолжить выполнение.

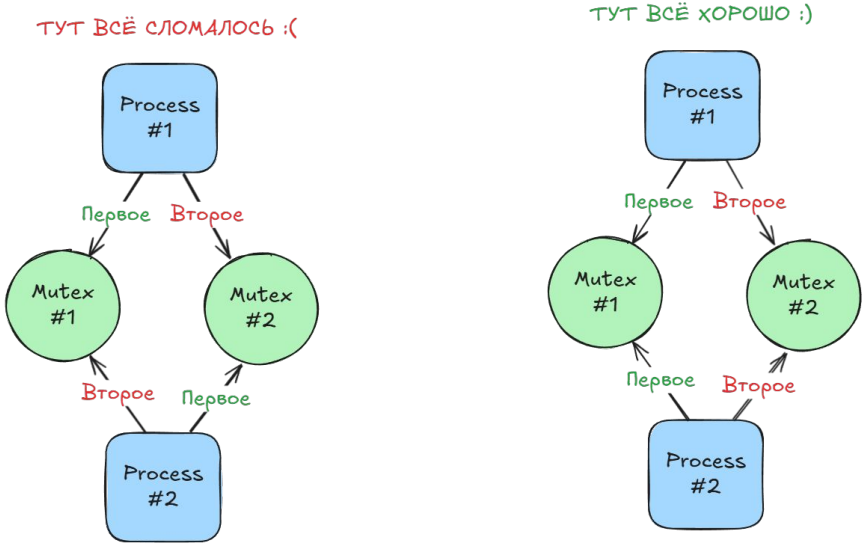

Мораль истории

Делайте захват и освобождение ресурсов в одном порядке в коде, который будет исполнен множеством потоков

Такие ошибки можно исправлять следующими способами:

- Проигнорить (не надо)
- Упорядочить захват ресурсов (надо)
- Использовать таймауты при блокировке (лениво)
- Применять алгоритмы избежания взаимоблокировок; например, алгоритм банкира (overkill)

Усвоили урок, перепишем реализацию mutex

```
struct Mutex {
    int victim;
};

void lock(Mutex *mutex) {
    int i = gettid();  // Для этого примера считаем, что
    mutex->victim = i; // потоков всего может быть 2 на процесс
    while (mutex->victim == i);  // Просто ждём, ничего не делаем
}

void unlock(Mutex *mutex) {}
```

Взаимоблокировки тут не будет, а что не так?..

Алгоритм Петерсона

```
struct Mutex {
    bool flag[2];
    int victim;
};

void lock(Mutex *mutex) {
    int i = gettid(); // Для этого примера считаем, что
    int j = 1 - i;    // потоков всего может быть 2 на процесс
    mutex->flag[i] = true;
    victim = i;
    while (flag[j] && victim == i);  // Просто ждём, ничего не делаем
}

void unlock(Mutex *mutex) {
    int i = gettid();
    flag[i] = false;
}
```

Семафоры

Примитив синхронизации, используемый для управления доступом к ограниченному количеству ресурсов или координации потоков.

- Имеет в себе счётчик, начальное значение которого можно задать при создании семафора, т.е. похож на **int**
- Имеет простой интерфейс: **wait** и **post**
- Применяется, если с ресурсом можно работать параллельно больше, чем одному потоку

Захват семафора (**wait**) декрементирует внутренний счетчик, а освобождение – инкрементирует.

Поток будет ждать при захвате, пока счётчик не станет больше 0.

Спины!

Spin-mutex – примитив синхронизации с **активным ожиданием**, который в точности повторяет поведение обычного мьютекса. Но есть отличия:

- Spin-mutex является **великолепным `while(true)`**
- Потоки, которые пытаются заблокировать такой мьютекс, если его уже захватили, будут **висеть в бесконечном цикле**, вместо того чтобы спать
- Спин-мьютекс реализован стандартной библиотекой **в пользовательском коде**, в отличие от обычного мьютекса, где логика работы реализована в ядре (syscall)
- Его использование оправдано в коде, если он защищает участок, который не имеет системных вызовов и занимает мало процессорного времени

Реализация spin-mutex

```
struct SpinMutex {
    volatile bool flag;
};

extern void lock_spin_mutex(SpinMutex *spin);

void unlock_spin_mutex(SpinMutex *spin) {
    spin->flag = false;
}
```

```
;;; spin_mutex.asm
Spin_mutex_lock: ; Аргумент-указатель на SpinMutex находится в регистре rdi
    mov al, 0                ; Ожидаем увидеть во флаге 0
    mov bl, 1                ; Если увидели 0, то флаг должен стать 1
try_lock:
    lock cmpxchg [rdi], bl   ; Атомарно сравнить mutex->flag с al и установить bl
    je lock_acquired         ; Если обмен успешен (ZF=1), мьютекс захвачен
    pause                    ; Инструкция PAUSE для снижения нагрузки
    jmp try_lock             ; Повторить попытку
lock_acquired:
    ret                      ; Возврат из функции
```

Атомики!

Атомарные операции – это низкоуровневые операции, выполняемые за один такт процессора без прерывания другими потоками.

- Используют аппаратные инструкции процессора и зависят от его архитектуры для атомарного выполнения
- Поддерживают операции чтения, записи, инкремента, сравнения-и-обмена (compare-and-swap)
- Используются для простых операций (например, счётчики, флаги).

- Атомарные операции **не бесплатны** – процессор **приостановит** все остальные ядра, пока одно ядро выполняет атомарную операцию!

Condition variable

Условная переменная – примитив синхронизации для координации потоков, позволяющий им ожидать выполнения определённого условия

- Имеет простой интерфейс: **wait** и **broadcast**
- **Связан с другим примитивом синхронизации** (обычно мьютекс)**,** поэтому cond. var. **является просто сигналом для другого ПС**
- Вы сами пишите **условие (if-else) на языке программирования**, когда потоки должны подождать (**wait**) и потом проснуться (**broadcast)**

Condition variable

- Поток вызывает **wait**, чтобы приостановиться и ждать сигнала (спать), если условие не выполнено. При этом он освобождает связанный примитив синхронизации
- Другой поток, изменивший условие, вызывает **broadcast**, чтобы возобновить один или все ждущие потоки. При это все ждущие потоки захватывают связанный примитив синхронизации

Отличия condition variable от semaphore

Condition variable	Semaphore
● Ожидание выполнения условия, связанного с общим ресурсом ● **broadcast** освобождает **все** потоки ● Требует примитив синхронизации для защиты условия и критической секции ● Поток ждёт сигнала **broadcast**, если ранее заснул на **wait**	● Управление доступом к ограниченному количеству ресурсов ● **post** освобождает место для работы **одного** потока ● Является самостоятельным примитивом синхронизации ● **wait** инкрементирует внутренний счетчик, **post** – декрементирует

Практический пример: барьер потоков

```c
typedef struct {
    pthread_mutex_t mutex; // Мьютекс для защиты данных барьера
    pthread_cond_t cond;   // Условная переменная для ожидания
    int count;             // Текущий счётчик достигших потоков
    int total;             // Общее количество потоков для барьера
} Barrier;


void barrier_wait(Barrier *barrier) {
    pthread_mutex_lock(&barrier->mutex);
    barrier->count++;

    if (barrier->count < barrier->total) {
        // Поток ждёт, пока все не достигнут барьера
        pthread_cond_wait(&barrier->cond, &barrier->mutex);
    } else {
        // Последний поток уведомляет все ждущие
        barrier->count = 0; // Сбрасываем счётчик для следующего использования
        pthread_cond_broadcast(&barrier->cond);
    }

    pthread_mutex_unlock(&barrier->mutex);
}
```

Барьер потоков